

Étude de la qualité de l'air en France en janvier et février 2025

Projet de statistique 2025-2026
L1 CMI ISI - Université de Bordeaux

Baptiste du Reau

23 avril 2026

Supervisé par Jérémie Bigot

Table des matières

- 1 Introduction**
- 2 Description et traitement des données**
 - 2.1 Données utilisées
 - 2.2 Choix de la méthode d'analyse
 - 2.3 Nettoyage des données
- 3 Statistiques**
 - 3.1 Urbain / Rural
 - 3.2 Moyennes en France
 - 3.3 Moyennes par site
 - 3.4 Dépassement du seuil recommandé
- 4 Utilisation de données complémentaires**
 - 4.1 Analyse insuffisante
 - 4.2 Introduction de nouveaux paramètres
 - 4.3 Indice de qualité de vie
- 5 Conclusion**

Références

1 Introduction

Avant de déménager dans une autre ville, on peut avoir envie de trouver laquelle est la meilleure pour y vivre. On pense souvent à regarder le travail disponible, la quantité et la proximité des commerces, les espaces verts et bien d'autres paramètres, mais on oublie souvent de s'intéresser à notre santé. En effet, certains peuvent penser à regarder les médecins à proximité, donc pour se soigner, mais personne ne vérifie jamais la pollution de la ville, ce qui permettrait de prévenir certaines maladies, surtout pour les personnes de constitution fragile. Il est donc important de s'y intéresser, surtout si on compte passer le reste de notre vie dans cette ville, car en vieillissant on devient plus susceptible de tomber malade à cause de cette pollution.

Le terme de pollution peut paraître vague, on va donc le préciser : selon le Larousse^[1], la pollution est : «*[La] Dégradation de l'environnement par des substances (naturelles, chimiques ou radioactives), des déchets (ménagers ou industriels) ou des nuisances diverses (sonores, lumineuses, thermiques, biologiques, etc.)*». Parmi les trois pollutions décrites ci-dessus, la plus susceptible d'avoir un impact sur notre santé est la pollution par des substances. Pour être plus précis, la pollution qui va nous intéresser est la pollution de l'air par des substances chimiques, car elle est présente partout et tout le monde y est exposé.

Mais encore une fois, la « pollution de l'air » n'est pas très précis, mais d'après l'OMS^[2] : « *Air pollutants with the strongest evidence for adverse health outcomes include particulate matter (PM; both PM_{2.5} [...] and PM₁₀ [...]), ozone (O₃), nitrogen dioxide (NO₂), sulfur dioxide (SO₂) and carbon monoxide (CO). Air pollution is however composed of many more pollutants.* ». Parmi tout ces polluants, les plus représentatifs sont les PM₁₀ et les PM_{2.5} car ils englobent un nombre conséquent de polluants et sont mesurés dans un grand nombre de stations en France. Enfin, parmi ces deux catégories, nous allons étudier les PM_{2.5} car ces particules sont quatre fois plus petites et donc beaucoup plus dangereuses pour la santé.

L'étude des concentrations de ces particules en France nous permettra ainsi de répondre à la question :

Quelle ville de France possède les meilleures conditions de vie ?

2 Description et traitement des données

2.1 Données utilisées

On s'intéresse à des observations qui sont collectées sous la forme d'une concentration en $\mu\text{g}/\text{m}^3$ des particules de $\text{PM}_{2.5}$ dans l'air. Les données ont été enregistrées pendant les 4 premières semaines des mois de janvier et de février 2025, pour un total de 56 jours. L'intervalle de temps entre chaque mesure est de 1 heure.

Le $\text{PM}_{2.5}$, pour « Particulate matter 2.5 μm » est une catégorie de particules fines présentes dans l'air dont le diamètre est inférieur à 2.5 μm (taille d'une bactérie). La petite taille de ces particules leur permettent d'aller au plus profond de nos poumons, ce qui a donc des effets non-seulement sur la santé respiratoire, mais aussi sur la santé cardiovasculaire et aggravent le risque de maladies neurodégénératives.

Ces données ont été prises sur le site de Goed'air^[3] (GEstion des données d'Observation de la qualité de l'AIR) dont le but est de centraliser les données de mesure de polluants réglementés dans chaque région de métropole et d'outre-mer, et également de produire des statistiques horaires, journalières, saisonnières et annuelles sur les niveaux de concentration dans l'air ambiant selon des règles définies au niveau européen. Cette plateforme se propose d'agréger des observations sur la qualité de l'air physique à partir de sources de données fournies par l'Ineris au titre du Laboratoire Central de Surveillance de la Qualité de l'Air (LCSQA). Actuellement, les données disponibles proviennent de plusieurs dizaines de sites répartis sur tout le territoire français.

Une fois les données récupérées grâce à l'option "Export avancé" disponible sur Geod'air, toutes ces données extraites ont été regroupées dans le fichier JanvierFevrier.csv.

Ce fichier contient les données (en lignes) de 261 stations de mesures différentes sur les 56 premiers jours de l'année 2025, qui sont réparties en 23 catégories (en colonnes), dont les noms sont :

- "Date de début" **Date de début de l'enregistrement des données**
- "Date de fin" **Date de fin de l'enregistrement des données**
- "Organisme"
- "code zas"
- "Zas"
- "code site"
- "nom site" **Noms des sites de mesures des données**
- "type d'implantation" **Urbaine, Périurbaine, Rurale près des villes, Rurale nationale, Rurale régionale**
- "Polluant" **On n'a téléchargé que des données concernant le $\text{PM}_{2.5}$, donc toutes les données de cette colonne seront "PM2.5"**
- "type d'influence" **Fond, Industriel ou Trafic**
- "Réglementaire"
- "type d'évaluation"
- "type de valeur"
- "valeur" **Valeur du capteur arrondie au dixième près**
- "valeur brute" **Valeur brute du capteur, précis à 5 millièmes près**

- “unité de mesure”
- “taux de saisie”
- “couverture temporelle”
- “couverture de données”
- “code qualité”
- “validité”
- “Latitude” Permettent de localiser la station dans le monde
- “Longitude” Permettent de localiser la station dans le monde

Beaucoup de ces données ne nous seront pas utiles, il nous sera donc utile de trier ces données pour ne garder que celles importantes.

2.2 Choix de la méthode d’analyse

Afin d’analyser ces données, nous allons utiliser le langage de programmation R, que nous allons utiliser à l’aide de Rstudio. Le choix de ce langage est évident, puisqu’il a été spécialement créé pour faire de l’analyse et de la visualisation de données. En effet, il possède déjà un nombre important de fonctions statistiques intégrées, ainsi que diverses extension qui nous permettront d’afficher facilement des cartes et des graphiques.

2.3 Nettoyage des données

Une fois le fichier [JanvierFevrier.csv](#) importé dans **R**, on va nettoyer les données en ne gardant que les données utiles, c’est-à-dire les dates de début et de fin des enregistrements, les noms des stations de mesures, les types d’implantations et d’influences, les valeurs, les valeurs brutes, la latitude et la longitude.

Et comme les valeurs sont toutes des chaînes de caractère, on va convertir les valeurs et les valeurs brutes en nombres, et les dates de début et de fin en format de date, afin de pouvoir traiter directement ces données en tant que valeurs. Par souci de simplicité on va aussi renommer la colonne “nom site” en “Noms”.

Enfin, on remarque que certaines stations contiennent uniquement des valeurs invalides et nous seront donc inutiles, on peut donc les supprimer, ce qui nous laisse avec seulement 257 stations ayant des données, même si certaines possèdent toujours majoritairement des valeurs invalides.

3 Statistiques

3.1 Urbain / Rural

Tout d'abord, les capteurs n'ont pas tous les mêmes valeurs moyennes selon leur type d'implantation :

-Urbaine : $13,8 \mu\text{g}/\text{m}^3$

-Périurbaine : $13,3 \mu\text{g}/\text{m}^3$

-Rurale divers : $<12 \mu\text{g}/\text{m}^3$


Comme on pouvait s'y attendre, les capteurs en zones urbaines et périurbaines sont plus pollués que les capteurs en zones rurales. De plus, nous ne nous intéressons qu'aux villes, nous n'allons donc garder que les stations implantés en zones urbaines et périurbaines.

3.2 Moyennes en France

La moyenne totale en $\text{PM}_{2,5}$ dans les villes de France en janvier - février 2025 était d'environ $13,7 \mu\text{g}/\text{m}^3$, ce qui est relativement élevé étant donné que les seuils à ne pas dépasser recommandés par l'OMS^[4] sont de $15 \mu\text{g}/\text{m}^3$ dans la journée, qui peut être dépassé 3 à 4 fois dans l'année, et $5 \mu\text{g}/\text{m}^3$ dans l'année. Il faut cependant prendre en compte que ces particules sont plus présentes dans la première moitié de l'année^{[5], [6]} à cause de leur émission par les feux de bois en hiver ainsi que l'activité agricole au printemps. Pour cette raison, nous n'allons utiliser seulement le seuil quotidien de $15 \mu\text{g}/\text{m}^3$.


En calculant la moyenne quotidienne de toutes les stations en France, on se rend compte qu'elle dépasse plusieurs fois le seuil de l'OMS, 21 jours pour être exact, donc plus de un tiers du temps étudié (cf courbe ci-dessous). Cela signifie donc que plusieurs stations ont dépassé, parfois de beaucoup, ce seuil ce qui rend ces villes potentiellement dangereuses pour la santé.

Moyenne de la concentration journalière en $\text{PM}_{2,5}$ en France en Janvier - Février 2025.




3.3 Moyennes par site


La première chose que nous pouvons regarder est la moyenne totale de chaque site sur janvier – février :




La station ayant la moyenne la plus élevée est celle de « Bethune Stade », avec une moyenne de 23,1 µg/m³, ce qui est très élevé, mais ce n'est pas la seule station dont la moyenne est supérieure à 15 µg/m³. En effet 82 stations ont une moyenne au dessus du seuil de l'OMS (cf carte ci-dessous), ce qui est inquiétant car cela signifie que ces villes ont été bien plus que 3 ou 4 jours au dessus du seuil recommandé par l'OMS.



En calculant le coefficient de corrélation entre la latitude et la moyenne en $PM_{2.5}$ de chaque station, on se rend compte qu'il existe une corrélation positive modérément forte qui dit que plus une station est au nord, plus elle est polluée (on peut d'ailleurs le voir à l'œil sur la heatmap ci-dessous). Cela peut se comprendre par le fait que les températures y sont plus basses en hiver, et il y a donc besoin de plus de chauffage, ce qui fait monter les concentrations en $PM_{2.5}$ (du moins le chauffage à bois).




Quand à l'Est de la France, on peut supposer que cette concentration plus élevée est due à la présence de relief important, notamment à cause des Alpes (cf carte ci-dessous), et comme la température est plus basse à altitude plus élevée, il y aurait là aussi plus besoin de chauffage.



3.4 Dépassement du seuil recommandé

En comptant le nombre de fois où la moyenne quotidienne de chaque station dépasse $15 \mu\text{g}/\text{m}^3$, on se rend compte que seules 20 stations respectent la recommandation de l’OMS de ne dépasser le seuil recommandé moins de 5 fois :



C’est inquiétant car cette étude ne se base que sur les données de janvier et février et on peut donc supposer que ces stations vont encore dépasser le seuil un certain nombre de fois au cours de l’année. De plus, certaines villes possèdent plusieurs stations, et il y a donc moins de 20 villes en France qui respectent cette recommandation. Pour être plus précis, seules 6 stations n’ont jamais dépassé ce seuil, et aucune d’entre elles ne se situe en métropole. Les deux seules stations en métropole qui respectent les recommandations de l’OMS sont : « Aurillac-Lagarde » et « Biarritz-hippodrome », qui n’ont dépassé ce seuil « que » 3 fois sur cette période. Deux autres stations en métropole n’ont dépassé le seuil « que » deux fois, mais nous ne les prendrons pas en compte à cause d’un trop grand nombre de valeurs invalides.

4 Utilisation de données complémentaires

4.1 Analyse insuffisante

Si l'on arrêta cette étude ici, on pourrait croire que les villes d'Aurillac et de Biarritz sont les deux seules villes de France métropolitaines où aller, et sinon il faudrait aller en Corse ou en Outre-mer, là où les concentrations en $PM_{2.5}$ sont plus basses (sauf en Guyane). Mais ce n'est évidemment pas ce qui se passe, tout le monde ne se rue pas sur ces villes, et ce pour une bonne raison : nous ne prenons pas en compte tous les paramètres. En effet, il ne serait pas très judicieux de notre part de réduire notre choix de ville où habiter simplement sur la qualité de l'air, on va donc introduire de nouvelles données afin de mieux pouvoir choisir notre ville idéale.

4.2 Introduction de nouveaux paramètres

Tout d'abord, il faut prendre en compte la taille des villes, que l'on peut mesurer soit par sa superficie soit par sa population. Nous allons utiliser la population de chaque commune disponible sur un jeu de données gouvernemental^[7]. Cette information est très importante car plus une ville est grande, plus elle a de moyens, d'infrastructures, de médecins, etc. et donc plus la qualité de vie y est élevée.

Puisque nous nous intéressons à la santé, il faudrait s'intéresser à l'accessibilité aux soins. Pour cela on pourrait faire une estimation du nombre de médecins par ville en se basant sur leur population. Sachant qu'il y a environ 237 200 médecins en activité^[8] pour environ 69 082 000 français^[9], cela fait donc environ 3,43 médecins pour 1000 habitants. Mais cela est très approximatif, et même si le nombre de médecins était correct avec cette estimation (ce qui est déjà improbable), cela ne nous donne aucune information sur la disponibilité de ces médecins. Heureusement, il existe un indicateur déjà calculé^[10] qui prend en compte la quantité de médecins généraliste, ainsi que l'offre et de la demande : c'est l'« APL (Accessibilité Potentielle Localisée) aux médecins généralistes » qui est disponible pour toutes les communes.

Enfin, on peut aussi s'intéresser au salaire médian de chaque commune, qui reflète directement sa qualité de vie. Encore une fois, ces données sont disponibles sur un jeu de données gouvernemental^[11].

4.3 Indice de qualité de vie

Avec tous ces nouveaux paramètres plus représentatifs de la qualité de vie, on va pouvoir calculer et attribuer un indice de qualité de vie à chaque commune, et ainsi trouver la ville idéale où vivre. Malheureusement, il reste encore un dernier obstacle pour pouvoir utiliser les résultats de notre analyse de la qualité de l'air : nous ne savons pas exactement à quelle commune appartient chaque station, ce qui est nécessaire pour pouvoir utiliser ces nouvelles données. Assigner une commune à chaque station manuellement aurait pris un temps considérable, heureusement, le site de données gouvernementales possède une API^[12] qui nous permet d'obtenir des informations à partir des coordonnées, que nous possédons.

Après avoir importé et trié toutes ces nouvelles données, on peut maintenant calculer l'indice de qualité de vie. Nous allons utiliser les ordres de grandeurs suivants :

- 37,5 % pour l'APL aux médecins généralistes
- 27,5 % pour le revenu médian
- 17,5 % pour la population
- 17,5 % pour la qualité de l'air (en $PM_{2.5}$)


Attention : Cet indice de qualité de vie n'est pas absolu. En effet chaque personne a ses propres critères, ses propres goûts, etc. Le classement que nous établirons à l'issue du calcul de cet indice est donc à prendre avec précaution, nous vous invitons à recalculer vous-même cet indice avec vos propres ordres de grandeurs (vous pouvez pour cela réutiliser le code et les calculs mis à disposition sur le GitHub^[13] du projet).

Ici, nous avons décidé de mettre en avant l'APL aux médecins généralistes car nous nous concentrons plus sur l'aspect santé.

Ensuite vient le revenu médian de la commune car un revenu médian élevé implique que la ville dispose de moyens élevés et donc potentiellement plus d'infrastructures médicales.

Quand à la population et la qualité de l'air, leur pondération est plus faible car leur méthode de calcul est différente. En effet, pour la population, on a pris une courbe gaussienne de formule :


$$\exp\left(\frac{(Population - 200\,000)^2}{2 * 150\,000^2}\right)$$





Ici aussi un choix a été fait : 200 000 a été choisi comme taille « idéale » de ville, mais cela aussi est subjectif.

Idem pour 150 000, qui est la tolérance sur la population (la largeur de la courbe)

Enfin, la formule de calcul pour la qualité de l'air est une exponentielle qui explose lorsque les valeurs dépassent $15\mu g/m^3$, et donc qui pénalise fortement les villes qui dépassent les recommandations de l'OMS.




On peut donc maintenant calculer chaque index de qualité de vie pour chaque station :



Comme attendu on retrouve bien en top position les relativement grandes villes pas trop polluées (cf heatmap ci-dessus)

Le top 10 :

1. Bordeaux
2. La Mulatière (Lyon)
3. Talence (Bordeaux)
4. Annecy
5. Anglet (Biarritz)
6. Aix-en-Provence
7. Saint-Paul (Outre-mer : Saint-Denis)
8. Angers
9. Vannes
10. La Rochelle



5 Conclusion

Les résultats de notre analyse nous ont montré qu'il existait une corrélation non-négligeable entre la latitude et la pollution moyenne des villes. En effet, dans les données étudiées les villes les plus au nord étaient clairement plus polluées que les autres. Il faut cependant se rappeler que la période temporelle couverte par notre jeu de données n'est pas très grande et que cette différence notable des villes du nord peut s'expliquer par la saison étudiée qui y est plus propice. De plus, il se peut que cette différence soit exceptionnelle et ne se reproduise pas chaque année.

On a aussi pu remarquer que quasiment aucune ville française ne respectaient les recommandations quotidiennes de l'OMS de ne dépasser une concentration de $15\mu\text{g}/\text{m}^3$ au maximum 3 ou 4 fois dans l'année et que la plupart des villes à avoir respecté ce seuil se situaient en Outre-mer.

Enfin, afin de répondre à la question : « Quelle ville de France possède les meilleures conditions de vie ? », nous avons introduits de nouvelles données qui nous ont permis de calculer un indice de qualité de vie pour chaque ville. Cette indice de qualité de vie prenait en compte l'accès aux soins, le revenu médian, la taille des villes et la qualité de l'air. Cette indice nous a permis de voir que les villes avec les meilleures conditions de vie se situaient globalement au sud et à l'ouest de la France, avec la métropole de Bordeaux en tête du classement (avec Bordeaux en 1^{ère} place et Talence en 3^{ème} place).

Il faut cependant nuancer ces résultats à cause la période temporelle couverte et de l'absence de certains paramètres. En effet, pour calculer un indice de qualité de vie réaliste, il aurait fallu prendre en compte un certain nombres de paramètres supplémentaires, tels que le niveau de végétalisation de la ville, la proximité et la quantité des commerces, les établissements scolaires, etc.

Références

- [1] Larousse → Pollution
(<https://www.larousse.fr/dictionnaires/francais/pollution/62217>)
- [2] OMS → Lignes directrices sur la pollution atmosphérique et la santé
(<https://www.who.int/tools/compendium-on-health-and-environment/air-pollution-and-health>)
- [3] Geod'air
(<https://www.geodair.fr>)
- [4] OMS → Lignes directrices OMS relatives à la qualité de l'air
(<https://www.who.int/fr/publications/i/item/9789240034433>)
- [5] SDES → « La pollution de l'air par les particules fines de diamètre inférieur ou égal à 2,5 micromètres (PM2,5) »
(<https://www.statistiques.developpement-durable.gouv.fr/la-pollution-de-lair-par-les-particules-fines-de-diametre-inferieur-ou-egal-25-micrometres-pm25>)
- [6] Airparif → « Les particules fines »
(<https://www.airparif.fr/les-particules-fines>)
- [7] DataGouv → Population municipale des communes – France entière
(<https://www.data.gouv.fr/datasets/population-municipale-des-communes-france-entiere>)
- [8] DREES → 237 200 médecins sont en activité en France au 1er janvier 2025
(<https://drees.solidarites-sante.gouv.fr/jeux-de-donnees/250728-DATA-demographie-des-medecins>)
- [9] INSEE → Population au 1^{er} janvier
(<https://www.insee.fr/fr/statistiques/5225246#graphique-figure1>)
- [10] Observatoire des territoires → Indicateurs
(https://www.observatoire-des-territoires.gouv.fr/outils/cartographie-interactive/#c=indicator&xi=apl.apl_mg_hmep&s=2023&view=map76)
- [11] Observatoire des territoires → Médiane du revenu disponible par UC
(<https://www.observatoire-des-territoires.gouv.fr/mediane-du-revenu-disponible-par-uc>)
- [12] DataGouv → API
(<https://api-adresse.data.gouv.fr/reverse/?lat=LATITUDE&lon=LONGITUDE>)
exemple : <https://api-adresse.data.gouv.fr/reverse/?lat=45.344078&lon=4.807481>
- [13] Github → ProjetQualiteAir
(<https://github.com/Baptou-33/ProjetQualiteAir>)